

**xg1990**

地理圈的码农


---

# 广义线性模型 学习笔记（一）——定义

## 0.引言

当对数据进行回归分析时，经常会用到两类回归模型：


一类是针对连续型数据进行的线性回归，如下图（图片来源：维基百科）所示



这种回归模型的公式是：

$$y = a_0 + a_1x_1 + a_2x_2 + \cdots + a_nx_n$$

还有一类是针对分类数据进行的**logistic**回归，如下图（[图片来源](#)）



这种回归模型的公式则是：

$$y = \frac{1}{1 + e^{-(a_0 + a_1x_1 + a_2x_2 + \cdots + a_nx_n)}}$$

这里形如

$$y = \frac{1}{1 + e^{-z}}$$

的函数被称为 **sigmoid** 函数。

那么问题来了：这两种回归模型，是否有可能统一到一种更加抽象的模型中？这两种形式完全不同的模型，是不是只是某种更加广义的模型的特例？

答案是肯定的，这个更加广义、抽象的模型就叫做广义线性模型(**Generalized Linear Model**)，简称 **GLM**。常见的线性回归、**logistic** 回归、泊松回归等等都是它的特殊形式。

不仅如此，在 **GLM** 的视角下，我们能够合理地解释：为什么**logistic** 回归要用**sigmoid** 函数  $y = \frac{1}{1+e^{-z}}$ ？为什么泊松回归要用指数函数  $y=e^{\{z\}}$ ？选择这些函数不仅仅是因为他们的函数曲线形状与观测值很接近，其背后有更加深层次的统计基础。

## 1. 广义线性模型的定义

广义线性模型建立在三个定义的基础上，分别为：

- 定义线性预测算子

$$\eta = \theta^T x$$

- 定义  $y$  的估计值

$$h(x, \theta) = E(y|x, \theta)$$

- 定义  $y$  的估值概率分布属于某种指数分布族：

$$\Pr(y|x, \theta) = b(y)\exp(\eta^T T(y) - a(\eta))$$

接下来详细解释各个定义

## 1.1. 定义一：线性预测算子

广义线性模型的名字中有『线性』两个字，自然它包含了线性计算的过程，也就是它的假设之一，定义线性预测算子(linear predictor)为：

$$\eta = \theta^T x$$

这里的  $\theta$  和  $x$  都是向量，写成标量形式就是：

$$\eta = \theta_0 x_0 + \theta_1 x_1 + \cdots + \theta_n x_n$$

通常  $x_0 = 1$ 。

不要问为何这么定义，这可以理解为『广义线性模型』约定的规则。

## 1.2. 定义二：期望估计

如果以概率论的方式解释回归（**regression**）这一过程，我们可以把通过给定的自变量  $x$ ，和相关的线性参数  $\theta$  估计因变量  $y$  的过程。理解为求解条件概率  $\Pr(y|x, \theta)$  的过程。也就是在给定了  $\eta = \theta^T x$  的条件下，求解因变量  $y$  的概率分布曲线。然后，计算这个概率分布的期望值  $E(y|x, \theta)$ ，作为  $y$  的估计值，同时这个概率分布的方差  $Var(y|x, \theta)$  作为  $y$  的估计值的方差。

因此第二个假设就是： $y$  的估计值就是  $\Pr(y|x, \theta)$  的期望值。如果用  $h(x, \theta)$  表示  $y$  的估计值，这一假设写为：

$$h(x, \theta) = E(y|x, \theta)$$

### 1.3. 定义三：指数分布族

在毫无头绪的情况下，要求解  $\Pr(y|x, \theta)$  的函数表达式不太可行。因此广义线性模型做出假设， $\Pr(y|x)$  的概率分布服从如下形式：

$$\Pr(y|x, \theta) = b(y)e^{\eta^T T(y) - a(\eta)}$$

注意，这里的  $\eta = \theta^T x$ ，因此这个概率分布也可以写成：

$$\Pr(y|\eta) = b(y)e^{\eta^T T(y) - a(\eta)}$$

其中  $b(y)$ ， $T(y)$  是  $y$  的函数， $a(\eta)$  是  $\eta$  的函数。 $a, b, T$  这三个函数的形式未知，是一种抽象的表达方式。一般情况下  $T(y) = y$ ，后文中所有  $T(y)$  都会直接写成  $y$ 。

凡是能写成这个形式的概率分布函数，都称之为指数分布族中的一种特例。如果  $a, b, T$  选择某种特殊的函数形式，指数分布族就会退化为某种特殊的概率分布（比如二项分布、正态分布），而具体的分布形式就会对应了具体的回归模型。

后文将具体介绍  $a, b, T$  在什么形式下会变为常见的回归模型。本文还将继续对这个GLM进行抽象地分析。

## 2. 广义线性模型的特征

为什么要把  $y$  的条件分布定义为这么奇怪的指数分布族？这是因为，在这样的定义下，我们可以证明：

- $\Pr(y|\eta)$  的期望值

$$E(y|\eta) = \frac{d}{d\eta} a(\eta)$$

- $\Pr(y|\eta)$  的方差

$$Var(y|\eta) = \frac{d^2}{d\eta^2} a(\eta)$$

如此简洁的期望和方差意味着：一旦待估计的  $y$  的概率分布写成了某种确定的指数分布族的形式（也就是给定了具体的  $\mathbf{a}, \mathbf{b}, \mathbf{T}$ ），那么我们可以直接套用公式  $h(\mathbf{x}, \theta) = E(y|\mathbf{x}, \theta) = \frac{d}{d\eta} a(\eta)$  构建回归模型。通过这个规律，我们可以解释为什么 **logistic** 回归要用 **sigmoid** 函数  $y = \frac{1}{1+e^{-z}}$  建模。

指数分布族的这两个特征如此简洁，以至于我忍不住试着证明这两个结论。如何通过 **GLM** 得出常见的线性模型、**logistic** 回归则在后面的博客中介绍。

### 2.1. 证明指数分布族的期望

首先定义似然函数  $L(y, \eta)$ ：

$$L(y, \eta) = \log \Pr(y|\eta) = \log(b(y)e^{\eta y - a(\eta)})$$

化简为:

$$L(y, \eta) = \log(b(y)) + \eta y - a(\eta)$$

再定义其对  $\eta$  的倒数 U:

$$U(y, \eta) = \frac{d}{d\eta} L(y, \eta) = y - \frac{d}{d\eta} a(\eta)$$

可以证明  $U(y, \eta)$  的期望  $E(U(y, \eta)) = 0$  (证明过程放在后面), 那么有

$$E(y - \frac{d}{d\eta} a(\eta)) = 0$$

$$E(y) = E(\frac{d}{d\eta} a(\eta))$$

因为

$$\frac{d}{d\eta} a(\eta)$$

是一个与  $y$  无关的函数, 因此

$$\frac{d}{d\eta} a(\eta)$$

的期望就是它本身，因此

$$E(y) = \frac{d}{d\eta} a(\eta)$$

### 2.1.1 证明 $E(U) = 0$

接下来证明为什么  $E(U) = 0$

之前定义了

$$U(y, \eta) = \frac{d}{d\eta} L(y, \eta) = \frac{d}{d\eta} \log \Pr(y|\eta)$$

带入其期望公式

$$E(U(y, \eta)) = \int U(y, \eta) \Pr(y|\eta) dy$$

中，则有：

$$E(U(y, \eta)) = \int \frac{d}{d\eta} \log \Pr(y|\eta) \Pr(y|\eta) dy$$

考虑到



$$d \log \Pr(y|\eta) = \frac{1}{\Pr(y|\eta)} d \Pr(y|\eta)$$

，有

$$E(U(y, \eta)) = \int \frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \Pr(y|\eta) \Pr(y|\eta) dy$$

化简得到

$$E(U(y, \eta)) = \int \frac{d}{d\eta} \Pr(y|\eta) dy$$

将微分符号提取出来，有

$$E(U(y, \eta)) = \frac{d}{d\eta} \int \Pr(y|\eta) dy$$

考虑到概率分布的归一化条件

$$\int \Pr(y|\eta) dy = 1$$

，则有

$$E(U(y, \eta)) = \frac{d}{d\eta} 1$$

常数的微分为0，因此

$$E(U(y, \eta)) = 0$$

## 2.2. 证明指数分布族的方差

先分析 $E(U^2)$ ，带入 $U(y, \eta) = y - \frac{d}{d\eta} a(\eta)$ ，有：

$$E(U^2(y, \eta)) = \int (y - \frac{d}{d\eta} a(\eta))^2 \text{Pr}(y|\eta) dy$$

注意，刚刚已经证明了 $E(y) = \frac{d}{d\eta} a(\eta)$ ，带入上式中，有

$$E(U^2(y, \eta)) = \int (y - E(y))^2 \text{Pr}(y|\eta) dy$$

注意， $y$  的方差的定义就是  $\text{Var}(y|\eta) = \int (y - E(y))^2 \text{Pr}(y|\eta) dy$

所以我们得到结论：

$$\text{Var}(y|\eta) = E(U^2(y, \eta))$$

又因为可以证明  $E(-\frac{d}{d\eta} U) = E(U^2)$ （具体证明过程放在最后）。那么有：

$$Var(y|\eta) = E(-\frac{d}{d\eta}U)$$

现在要求解

$$E(-\frac{d}{d\eta}U(y,\eta))$$

，将

$$U(y,\eta) = y - \frac{d}{d\eta}a(\eta)$$

带入其中，有：

$$Var(y|\eta) = E(-\frac{d}{d\eta}U(y,\eta)) = E(-\frac{d}{d\eta}(y - \frac{d}{d\eta}a(\eta))) = E(\frac{d^2}{d\eta^2}a(\eta))$$

同理，式子

$$\frac{d^2}{d\eta^2}a(\eta)$$

与  $y$  无关，其期望为常数，得证

$$Var(y|\eta) = \frac{d^2}{d\eta^2}a(\eta)$$

### 2.2.1 证明 $E(-\frac{d}{d\eta}U) = E(U^2)$

通过证明式子  $E(U^2 + \frac{d}{d\eta}U) = 0$  来证明  $E(-\frac{d}{d\eta}U) = E(U^2)$

之前定义了

$$U(y, \eta) = \frac{d}{d\eta} \log \Pr(y|\eta)$$

带入  $E(U^2 + \frac{d}{d\eta}U)$  中, 有

$$E((\frac{d}{d\eta} \log \Pr(y|\eta))^2 + \frac{d}{d\eta} (\frac{d}{d\eta} \log \Pr(y|\eta)))$$

用期望公式  $E(f(y)) = \int f(y) \Pr(y) dy$  展开, 有:

$$E(U^2 + \frac{d}{d\eta}U) = \int ((\frac{d}{d\eta} \log \Pr(y|\eta))^2 + \frac{d}{d\eta} (\frac{d}{d\eta} \log \Pr(y|\eta))) \Pr(y|\eta) dy$$

因为  $\frac{d}{d\eta} \log \Pr(y|\eta) = \frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \Pr(y|\eta)$ , 则有

$$E(U^2 + \frac{d}{d\eta}U) = \int [\frac{1}{\Pr(y|\eta)^2} (\frac{d}{d\eta} \Pr(y|\eta))^2 + \frac{d}{d\eta} (\frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \Pr(y|\eta))] \Pr(y|\eta) dy$$

根据微分的规则:

$$\frac{d}{d\eta} \left( \frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \Pr(y|\eta) \right) = \frac{d}{d\eta} \left( \frac{1}{\Pr(y|\eta)} \right) \frac{d}{d\eta} \Pr(y|\eta) + \frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \left( \frac{d}{d\eta} \Pr(y|\eta) \right)$$

$$\frac{d}{d\eta} \left( \frac{1}{\Pr(y|\eta)} \frac{d}{d\eta} \Pr(y|\eta) \right) = \frac{-1}{\Pr(y|\eta)^2} \left[ \frac{d}{d\eta} (\Pr(y|\eta)) \right]^2 + \frac{1}{\Pr(y|\eta)} \frac{d^2}{d\eta^2} \Pr(y|\eta)$$

帶入上式中，有

$$E(U^2 + \frac{d}{d\eta} U) = \int \left[ \frac{1}{\Pr(y|\eta)^2} \left( \frac{d}{d\eta} \Pr(y|\eta) \right)^2 + \frac{-1}{\Pr(y|\eta)^2} \left[ \frac{d}{d\eta} (\Pr(y|\eta)) \right]^2 + \frac{1}{\Pr(y|\eta)} \frac{d^2}{d\eta^2} \Pr(y|\eta) \right] \Pr(y|\eta) dy$$

消去相反項，有：

$$E(U^2 + \frac{d}{d\eta} U) = \int \left[ \frac{1}{\Pr(y|\eta)} \frac{d^2}{d\eta^2} \Pr(y|\eta) \right] \Pr(y|\eta) dy$$

再次化簡：

$$E(U^2 + \frac{d}{d\eta} U) = \int \left[ \frac{d^2}{d\eta^2} \Pr(y|\eta) \right] dy$$

交換微積分順序：

$$E(U^2 + \frac{d}{d\eta} U) = \frac{d^2}{d\eta^2} \int \Pr(y|\eta) dy$$

因为概率分布的归一化条件  $\int \Pr(y|\eta) dy = 1$ , 则有

$$E(U^2 - \frac{d}{d\eta} U) = \frac{d^2}{d\eta^2} 1 = 0$$

得证

$$E(-\frac{d}{d\eta} U) = E(U^2)$$

## 参考资料:

1. [http://en.wikipedia.org/wiki/Linear\\_regression](http://en.wikipedia.org/wiki/Linear_regression)
2. <http://alumni.media.mit.edu/~tpminka/courses/36-350.2001/lectures/day32/>
3. [https://www.stat.tamu.edu/~suhasini/teaching613/exponential\\_family.pdf](https://www.stat.tamu.edu/~suhasini/teaching613/exponential_family.pdf)
4. <http://www.rni.helsinki.fi/~boh/Teaching/GLMs/glmsl1.pdf>



打赏

本作品使用基于以下许可授权: Creative Commons Attribution-NonCommercial 4.0 International License.